

Hackathon BI PIPELINE - Projet de Data Science

WatsonIA – Détection de fraudes bancaires

Equipe 20 :

- Lisa NACCACHE (DIA 4) : Chef d'équipe
- Hiba NEJJARI (DIA 4)
- Neil MAHCER (DIA 4)
- Wendy DUONG (DIA 4)
- Cyprien MOUTON (DIA 4)
- Safa HORMI BOUAICHI (DIA 3)

1. Introduction et Contexte

Dans le contexte où les transactions bancaires numériques se multiplient, les banques font face à une augmentation continue des tentatives de fraude. Les fraudeurs adoptent des stratégies de plus en plus sophistiquées, rendant difficile la détection automatique par des règles fixes. C'est dans ce cadre que IBM pour notre Hackathon a fourni un dataset réel issu d'opérations bancaires effectuées entre 2016 et 2018, nous permettant de développer, d'entraîner et d'évaluer des modèles de détection de fraude.

Notre objectif est de concevoir un modèle d'Intelligence Artificielle capable de prédire si une transaction est frauduleuse (1) ou non frauduleuse (0), afin d'assister les équipes de sécurité bancaire dans la prise de décision en temps réel.

2. Problématique

Les fraudes sur les cartes bancaires représentent des pertes financières importantes pour les banques et leurs clients. La détection doit être rapide pour bloquer les transactions suspectes immédiatement, fiable pour éviter les fausses alertes qui pénalisent les clients et capable de généraliser car les fraudeurs changent continuellement de comportement.

Notre problématique est donc : Comment développer un modèle de Machine Learning capables d'identifier efficacement les transactions frauduleuses.

3. Description du dataset IBM

Les datasets à notre disposition sont les suivants :

`transactions_train.csv` dans lequel il y a toutes les transactions bancaires (montant, date lieu, carte utilisée, etc) ce sera notre base principale qui nous permettra de détecter des comportements inhabituels: montants anormaux, transactions dans d'autres villes etc.

`train_fraud_labels.json` qui indique si chaque transaction du train est frauduleuse (1) ou non (0), ce fichier contient la vérité terrain pour faire apprendre le modèle.

`cards_data.csv` dans lequel nous avons les informations techniques sur les cartes, ce qui nous aide à comprendre si la carte est à risque. ex: carte signalée sur le dark web qui est un indicateur fort de fraude.

`user_data.csv` qui nous fournit le profil des clients (âge, revenu, localisation, score, crédit, nombre de cartes), ce qui nous permet de comparer la transaction en fonction du profil du client par exemple revenu faible + gros achat = suspect.

`mcc_codes.json` qui nous fournit une classification des marchands (restauration, jeux en ligne, transport, etc) ce qui nous permet d'analyser les habitudes d'achat et repérer des achats dans des secteurs à risque (ex: casinos est un secteur avec plus de fraudes)

`evaluation_features.csv` nous donne les transactions sans label, à prédire pour la soumission. ce fichier ne sera pas utilisé pour notre entraînement, seulement pour faire le fichier de prédiction final.

4. Enjeux du cold start

Contrairement à de nombreux problèmes de classification, les clients présents dans l'ensemble d'entraînement ne sont pas les mêmes que ceux de l'ensemble d'évaluation

Cela signifie que notre modèle doit :

- Généraliser sans mémoriser les comportements spécifiques de certains utilisateurs.
- Se baser davantage sur des patterns de transactions, et non sur des identités.
- Être résilient face à des comportements nouveaux.

5. Méthodologie

Étant un groupe composé de six étudiants de la majeure Data & Intelligence Artificielle, nous avons choisi de nous organiser comme une véritable équipe projet, en répartissant les rôles selon les compétences de chacun afin d'assurer une complémentarité entre la partie technique, analytique et visuelle. En parallèle, nous avons mis en place un [GitHub](#) pour regrouper notre travail.

Compréhension du problème (Business Understanding)

- Identifier les enjeux liés à la fraude bancaire et les contraintes du projet (cold start, déséquilibre des classes).
- Définir les objectifs du modèle et les critères d'évaluation (AUROC, AUPRC, F1-score).

Exploration et compréhension des données (Data Understanding)

- Étudier la structure des fichiers, détecter les anomalies, les valeurs manquantes et comprendre les comportements transactionnels typiques.

Préparation des données (Data Preparation)

- Nettoyage, fusion et création de nouvelles features (variables temporelles, catégorielles, etc.), tout en évitant toute fuite de données (no leakage).

Modélisation (Modeling)

- Entraîner un modèle de Machine Learning (LightGBM) capable de gérer un fort déséquilibre des classes et de généraliser à de nouveaux clients.
- Réaliser une validation temporelle : **2016–2017 pour le train, 2018 pour la validation.**

Évaluation (Evaluation & Generalization)

- Mesurer la performance sur des données et clients jamais vus pour garantir la robustesse.
- Ajuster le seuil de classification selon la métrique la plus pertinente (F1 / AUPRC).

Visualisation et restitution (Visualization & Deployment)

- Créer un **dashboard interactif** pour présenter les résultats et les indicateurs clés du modèle.
- Générer le fichier final de soumission au format demandé (transaction_id, fraud_prediction).
- Rédiger une synthèse claire pour le rendu final.

Toutes ces tâches ont été définies de façon détaillée dans notre dépôt GitHub, dans le dossier Management > [tasks.md](#).

| Phase | Tâches principales | Membres responsables |
|-------------------------------|--|----------------------|
| ① Introduction & Contexte | Présentation du projet et du dataset IBM | Lisa & Cyprien |
| ② Data Exploration | Analyse exploratoire et visualisation initiale | Hiba |
| ③ Data Preparation | Nettoyage, fusion, création de features | Hiba & Lisa |
| ④ Machine Learning Modeling | Entraînement, choix du modèle, tuning | Neil & Wendy |
| ⑤ Evaluation & Generalization | Tests de robustesse et comparaison | Neil & Wendy |

| | | |
|--|---|------------------|
| 6 Data Visualization & Dashboard | Création du dashboard sur Power BI | Safa |
| 7 Génération du fichier de soumission | Production du CSV final pour l'évaluation | Hiba & Cyprien |
| 8 Documentation & Présentation | Rapport et présentation orale | Tous les membres |